

AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS

DIPLOMADO

INTRODUCCIÓN ANALÍTICA A LA CIENCIA

DE DATOS

PROYECTO 9:

Patrones de utilización del sistema ECOBICI

Equipo 9

Ayala López Elizabeth

Cruz Miguel Eduardo

Díaz López Marco Antonio

Romero Rossano Sebastián

Toriz Pacheco Vanessa

Valverde Guadalupe Hugo

Índice

1. Introducción	3
2. Objetivo General:.....	3
3. Datos y procedencia	3
4. Descripción de la base de datos:	4
5. Análisis y Limpieza de datos	5
6. Metodología y modelo	6
7. Modelo de aprendizaje no supervisado: Clustering	8
7.1 Resultados	8
8. Conclusiones	9
9. Modelo Complementario de Regresión	10
10. Limitaciones.....	11
11. Posibles extensiones.....	11
12. Referencias bibliográficas.....	12

1. Introducción

El sistema de bicicletas públicas implementado en la Ciudad de México, llamado Ecobici, se encuentra operado por la Secretaría de Movilidad y está diseñado principalmente para realizar trayectos cortos en menor tiempo y conectarse con otros medios de transporte de la Red de Movilidad de la Ciudad de México.

Para poder utilizar alguna de estas bicicletas, es necesario tomarla en cualquiera de las cicloestaciones ubicadas en la ciudad y devolverla en la estación más cercana a tu destino. También, existen diversos planes y tarifas para que las personas puedan utilizarlo según la frecuencia de uso.

El problema central de este proyecto consiste en comprender cómo se distribuyen los viajes en ecobici a lo largo de cada hora del día, además del mes del año y estación de la cual se retira para su uso, y determinar si existen comportamientos similares. Toda esta información resulta de utilidad, ya que cada estación registra un gran volumen de información importante sobre cada viaje.

Los comportamientos en los viajes pueden estar relacionados con fenómenos de saturación o desabasto de bicicletas en determinadas estaciones. Es por ello que, además de realizar un análisis descriptivo, se plantea utilizar técnicas de aprendizaje no supervisado para agrupar las estaciones de acuerdo con sus patrones horarios de utilización y, con ello, identificar patrones horarios de desabasto o saturación.

2. Objetivo General

Nuestro principal objetivo al realizar el análisis de estos datos y trabajar con los modelos de aprendizaje no supervisado, es analizar el comportamiento en la demanda de ecobici por hora y estación de la ciudad durante los doce meses del año 2025. Además de identificar perfiles de uso similares y estaciones con posible presión operativa para que, con toda esta información podamos orientar análisis posteriores sobre el desabasto o saturación de este transporte.

3. Datos y procedencia

Los datos utilizados fueron extraídos de los registros de viajes de ecobici para el periodo comprendido entre enero y diciembre de 2025 publicados por la Secretaría de Movilidad. Es decir, nuestra base contiene datos desde el 1 de enero de 2025 hasta el 31 de diciembre de 2025, correspondiente a los doce meses del año.

A su vez, se trabaja con el Catálogo de Ecobici para complementar el registro de los viajes con información geográfica y territorial de las estaciones. Esta base contiene datos como la estación, colonia, alcaldía, latitud y longitud de estas.

Para poder trabajar con esta gran cantidad de información obtenida durante estos meses, agrupamos todos los viajes durante esos meses para tener una sola base de datos y trabajar con ella de la mejor manera.

4. Descripción de la base de datos

La base datos *ECOBICI_RAW_202501_202512.rds*, es una agrupación de los datos obtenidos por mes publicados por la SEMOV, contiene información correspondiente a 20,134,900 observaciones y 9 variables, entre las cuales tenemos las siguientes:

- Genero_Usuario: Género registrado del usuario que hace uso del transporte, puede ser “M” que se refiere a masculino, “F” para femenino y “O” para otro.
- Edad_Usuario: Edad registrada del usuario que hace uso del servicio de ecobici.
- Bici: Número identificador de bicicleta.
- Ciclo_Estacion_Retiro: Identificador de cicloestación en la cual comienza el viaje en bicicleta.
- Fecha_Retiro: Fecha en formato día, mes y año en cuál se inicia el viaje.
- Hora_Retiro: Formato hora, minuto y segundo en el cuál inicia el viaje.
- Ciclo_EstacionArribo: Identificador de cicloestación de la cual se entrega la bicicleta.
- Fecha_Arribo: Fecha en formato día, mes y año en cuál termina el viaje.
- Hora_Arribo: Formato hora, minuto y segundo en el cuál termina el viaje.

La obtención de todos estos datos se realizó mediante la combinación de doce diferentes bases de datos para construir una única base de datos que contuviera toda la información del periodo seleccionado.

La decisión de seleccionar este periodo se debe a que buscamos evitar mezclar años con diferentes formas de captura y que el volumen de la base fuera manejable computacionalmente, ya que el trabajar con un recuento histórico de datos implicaría trabajar con millones de datos.

5. Análisis y Limpieza de datos

Antes de aplicar las técnicas de agrupamiento, es necesario realizar un proceso de preparación de los datos. Este proceso tiene como objetivo garantizar que las observaciones sean comparables entre sí y que la información cumpla con los requisitos de los algoritmos de agrupamiento.

Es por ello que, el proceso de preparación y limpieza de la base de datos constituye una parte fundamental para el desarrollo del modelo, ya que el trabajar con inconsistencias en la base de datos sesga el resultado final. Por lo que, durante este proceso, realizamos los siguientes pasos para asegurarnos de trabajar con los datos correctos:

1. Los archivos son cargados utilizando `colClasses = "character"`. La decisión busca evitar que `rbindlist()` encuentre columnas con tipos diferentes entre los archivos. Los doce archivos mensuales no siempre tienen los mismos tipos de datos, por lo que esta decisión se tomó para evitar errores al unirlos en una sola base.
2. La variable *edad_usuario* se convierte a formato numérico. Se consideran edades entre 12 y 90 años. Los valores fuera de este rango y los faltantes no se utilizan en el análisis, pero los viajes correspondientes se conservan en la base general, ya que la edad no interviene en los modelos.
3. La variable *Bici* se conserva como carácter ya que es un identificador y no debe considerarse como una variable numérica.
4. Se eliminaron registros duplicados para no contar con n registros del mismo viaje.
5. Para el tema de fechas y horas de uso de ecobici, se construyeron diversas variables a partir de variables existentes con el fin de obtener una mejor interpretación de los datos. Los registros que no pudieron ser interpretados se eliminaron.
6. Eliminamos registros que no corresponden al periodo a estudiar, para evitar que otros periodos afecten nuestro análisis. Esto con la finalidad de analizar únicamente los meses del año 2025.
7. El periodo de duración de los viajes queda acotado entre 1 a 180 minutos, sin eliminar los viajes de conteos generales de demanda.
8. En la variable género se conservan las categorías de “M”, “F”, “O”, y para los valores faltantes se coloca “no especificado”.
9. Se hizo limpieza de espacios entre el catálogo y la información mensual para los identificadores de viaje, esto con la finalidad de realizar una unión usando *left_join*.

Finalmente, después de realizar el análisis y limpieza de la base de datos, pudimos conservar la mayor parte de los datos originales.


6. Metodología y modelo

Ahora bien, el análisis de los viajes registrados entre enero y diciembre del 2025 nos ayudó a identificar patrones claros en su distribución de tiempo, lugar y operativa de los viajes hechos con las Ecobicis.

El análisis exploratorio es una parte fundamental para comprender la estructura de la demanda de ecobici antes de aplicar el modelo a nuestros datos, se sugiere que una gran parte de los viajes hechos a lo largo del día coincide con los horarios tanto para la entrada como la salida laboral.


En primer lugar, pudimos detectar que el número de viajes presenta una concentración importante en dos periodos importantes, uno por la mañana alrededor de las 8:00 hrs. y otro en la tarde, alrededor de las 17:00/18:00 hrs.

A su vez, el volumen de viajes es mayor entre semana y disminuye durante sábado y domingo, lo que refuerza la posible relación del uso de la ecobici para desplazarse a sus respectivos empleos.




Ahora, al hablar de dónde surgieron más viajes, los retiros de unidades se registraron con una gran diferencia principalmente en las alcaldías Cuauhtémoc, Benito Juárez y Miguel Hidalgo. Este patrón que se observa a lo largo de todo 2025, logra identificar en estas alcaldías es donde se presenta una mayor presencia de actividad profesional y económica, por lo que esta concentración de viajes podría estar relacionada con desplazamientos hacia los empleos. Como adicional tenemos que, varias de las estaciones con mayor número de retiros se localizan cerca

de estas mismas zonas, en especial cerca de otros medios de transporte público, destacando las estaciones de Buenavista, Juárez, Polanco, Roma y Chapultepec. Esto sugiere un posible uso de Ecobici como complemento de otros medios de transporte en trayectos cortos para llegar a los empleos.



Finalmente, al momento de analizar los arribos y retiros de los equipos, vemos que existe un desbalance entre el número de bicicletas que se reciben y las que se retiran. Algunas estaciones ubicadas en Polanco presentan un mayor número de retiros que de arribos, mientras que estaciones de la zona de Buenavista muestran una acumulación de unidades. Este patrón nos muestra una distribución desigual de bicicletas entre zonas y permite identificar posibles estaciones prioritarias para las estrategias de distribución.

En adición, tenemos que la mayor frecuencia de los viajes se concentran en una duración de entre 5 y 10 minutos, siendo esto coherente con la relación con típicos trayectos cortos para llegar al trabajo, escuela o lugares cercanos.



Después de analizar estas gráficas, podemos concluir que estos resultados muestran que las estaciones presentan comportamientos diferentes dependiendo de la zona y la hora del día, cosa con la cual analizaremos si existen perfiles de estaciones con patrones horarios similares.


7. Modelo de aprendizaje no supervisado

A partir de los resultados del análisis exploratorio se localizaron diferencias entre los patrones horarios de uso de cada una de las estaciones. Como no contamos con una variable objetivo, se utilizó un modelo de aprendizaje no supervisado mediante K-means, esto con la finalidad de segmentar las estaciones según la similitud de sus perfiles horarios.

Para poder aplicar lo mencionado anteriormente, cada estación fue representada según su perfil horario de retiros, es decir, cada fila corresponde a una estación, cada columna a una hora del día y cada valor a la proporción de los retiros totales de la respectiva estación según la hora. Para evitar perfiles poco representativos, sólo se consideraron en cuenta aquellas estaciones con al menos 50 retiros.


El número de clusters se definió mediante los métodos del codo y silueta. Ambos criterios respaldaron una solución de tres grupos, entonces este número se seleccionó.

7.1 Resultados



K-means identificó tres comportamientos diferentes. El clúster 1 representa un perfil predominantemente matutino, con una fuerte concentración de retiros entre las 7:00 y 8:00 horas, después la demanda disminuye considerablemente. Después tenemos al clúster 2 que es un grupo vespertino, donde la demanda aumenta en la tarde, su concentración principal se encuentra entre las 14:00 y 17:00 horas. Finalmente, el clúster 3 que, cuenta con actividad tanto matutina como vespertina y un máximo hacia el final de la jornada.

Por otro lado, los perfiles horarios no se distribuyen de manera homogénea entre alcaldías. Miguel Hidalgo presenta una participación importante de estaciones en el perfil vespertino, comportamiento consistente con los patrones vistos en zonas como Polanco, mientras que en Azcapotzalco predomina ampliamente el perfil matutino. Por otro lado, Cuauhtémoc, Benito Juárez, Coyoacán y Álvaro Obregón presentan predominantemente un comportamiento mixto. Estos resultados evidencian diferencias territoriales en la forma en que se distribuye la demanda a lo largo del día.



8. Conclusiones

El análisis nos muestra que la demanda de las Ecobicis no se distribuye de forma equitativa ni en los días de la semana, ni las horas ni en las ubicaciones de las estaciones. Pudimos ver que los viajes representaron patrones asociados con horarios de movilidad laboral y se presentan en su gran mayoría en las alcaldías claves para el mercado laboral. Complementando lo anterior, existen estaciones con diferencias importantes entre arribos y retiros, cosa que genera distintas necesidades a la hora de pensar en distribución.

En cuanto a las alcaldías, la demanda se concentra principalmente en Cuauhtémoc, Benito Juárez y Miguel Hidalgo, territorios caracterizados por una alta actividad económica y profesional. Al hablar de arribos y retiros, existieron diferencias importantes, algunas estaciones presentan una acumulación de bicicletas, mientras que otras registran una mayor salida de unidades, dando a conocer que no todas las estaciones tienen las mismas necesidades.

Después de haber aplicado los K-means como medida para encontrar grupos en común, el clustering complementó estas observaciones al identificar tres perfiles horarios diferenciados de estaciones: matutino, vespertino y mixto. La presencia de cada uno de estos grupos varía

según la alcaldía, mostrando que el comportamiento de las estaciones no solo depende del volumen de viajes, sino también de cómo se distribuye la demanda a lo largo del día.

Gracias a esto pudimos pasar de sólo analizar el volumen de los viajes, sino ya también pudimos reconocer diferentes tipos de comportamientos entre las estaciones.

Estas agrupaciones pueden ayudarnos a diseñar diferentes estrategias de redistribución de Ecobicis o de simple monitoreo. Pero, el análisis no permite determinar directamente si una estación está saturada o desabastecida, pues para contar con estos detalles necesitamos agregar información tanto de la capacidad de Ecobicis por estación y su disponibilidad, por ejemplo. Por lo tanto, los resultados obtenidos serán una primera aproximación para identificar comportamientos y zonas que podrían necesitar un análisis más detallado.

9. Modelo Complementario de Regresión

Como complemento al análisis del clustering, se desarrolló un modelo base de regresión lineal para la estación 271-272 Buenavista, pues esta fue la estación con mayor número de retiros. Es un modelo complementario, ya que no abarca todo el estudio que realizamos anteriormente con el modelo Clustering mediante K-means.

Este modelo tiene la finalidad de evaluar en qué medida la demanda horaria de una estación puede anticiparse a partir de retiros por hora, teniendo como variables explicativas la hora del día y el día de la semana. La hora se incorporó como variable categórica para permitir que cada periodo del día tenga un comportamiento diferente. Haremos una separación del 80% de las fechas para entrenamiento, mientras que el 20% final será para la prueba.

Como tal, los resultados muestran un fuerte efecto horario sobre la demanda. Los incrementos más grandes están entre las 6:00 hrs. y las 9:00 hrs.; mientras que por la tarde se ve otro incremento, solamente que acá no es tan marcado como el de la mañana. Confirmando así que la demanda de la estación tiene una estructura definida.

Como parte de los resultados, el modelo nos dijo que la hora del día y el día de la semana explican aproximadamente el 49.8% de la variabilidad fuera de la muestra.

El resultado obtenido con este modelo nos muestra que los patrones temporales contienen información relevante para anticipar la demanda, aunque por sí solos no son suficientes para explicar toda su variación.

La comparación entre valores de nuestra base de datos y los valores predichos, muestra que el modelo puede analizar el comportamiento habitual de los datos, pero presenta mayores dificultades ante picos altos de demanda. Por ello, el modelo debe interpretarse como una línea base predictiva, pero no como un modelo de predicción total.

Con este modelo, podemos concluir que, para obtener un mejor modelo de predicción y abarcar el tema de desabasto y saturación de las estaciones, es necesario conocer más información, y que este modelo por sí solo no es capaz de realizar una predicción real.

10.Limitaciones

- La base no incluye inventario ni anclajes libres. Un retiro registrado indica demanda satisfecha, pero no revela la demanda que se perdió por falta de bicicletas. Por eso no podemos afirmar que una estación esté saturada o desabastecida.
- El clustering ignora el volumen. Al trabajar con proporciones, dos estaciones con perfiles idénticos pero tamaños muy distintos quedan en el mismo grupo, aunque su necesidad operativa sea diferente.
- Perfiles que mezclan días hábiles y fines de semana. Un perfil promedio puede ocultar patrones distintos entre semana y en sábado o domingo.
- Representación desigual por alcaldía. Algunas alcaldías tienen pocas estaciones, por lo que su composición de clusters debe leerse con cautela.
- Regresión de una sola estación y sin variables externas. Sin clima, festivos ni eventos, el modelo captura la rutina habitual, pero falla ante picos extraordinarios.

11.Posibles extensiones

1. Incorporar disponibilidad en tiempo real para medir saturación y desabasto directamente y validar los perfiles encontrados.
2. Separar los perfiles por tipo de día (hábil, sábado, domingo y festivo) y repetir el clustering.
3. Agregar a los modelos información como el clima, días festivos, eventos y cercanía a otros medios de transporte y centros de trabajo.
4. Probar modelos más adecuados para conteos y extender la predicción a más estaciones, no solo a la de mayor demanda.

5. Analizar flujos origen y destino para identificar rutas donde se acumulan o faltan bicicletas, y proponer estrategias de redistribución.
6. Comparar con otros algoritmos de agrupamiento para comprobar que los tres perfiles son estables.

12. Referencias bibliográficas

- ECOBICI. (s. f.). *Datos abiertos*. Gobierno de la Ciudad de México. <https://ecobici.cdmx.gob.mx/datos-abiertos/>
- Secretaría de Movilidad. (s. f.). *Afluencia diaria del sistema ECOBICI*. Portal de Datos Abiertos de la Ciudad de México. <https://datos.cdmx.gob.mx/dataset/afluencia-diaria-del-sistema-ecobici>